Prediction 5:

- Nếu corpus rất nhỏ, trigram k chắc chắn tốt hơn bigram
- vì khi tập dữ liệu thưa thớt thì xác suất 1 cụm từ to thường sẽ thấp hơn cụm từ nhỏ
- confidence: ~~high~~ high (>95%)

Lab 03.

~~Bài~~ Bài 1.

dựa vào corpus với cấu trúc ma trận này, với $k = 1$ (xét 1 từ trái, 1 từ phải)

cat: [0, 0, 1, 1, 0, 0, 0]
dog: [0, 0, 1, 1, 0, 0, 0]
eats: [1, 1, 0, 0, 2, 0, 0]
likes: [1, 1, 0, 0, 0, 1, 1]

Bài 2:

$$\cos(x,y) = \frac{x \cdot y}{\|x\| \, \|y\|} = \frac{1.2 + 2.4 + 1.2}{\sqrt{1^2+2^2+1^2} \cdot \sqrt{2^2+4^2+2^2}} = 1.$$

Do 2 vector này cùng hướng tuyệt đối ($y = 2x$) có nghĩa là hai từ xuất hiện trong các ngữ cảnh giống nhau với một tỉ lệ phân bố mẫu T

thực hiện

$$\forall x,y : I \otimes T(x,y) = \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} I(x+i, y+j) * T(i,j)$$

Bài 3: So sánh semantic similarity

- dự đoán: doctor sẽ gần với physician hơn vì chúng là từ đồng nghĩa trong thực tế
- tính toán:
- Bài chữa: vector của từ đồng nghĩa có góc rất nhỏ (cosine xấp xỉ 1). vector của các từ k liên quan có thể trực giao (cosine ≈ 0) hoặc góc quay ngược nhau (cosine âm)

Bài 4. Sparse và dense

1. Biểu diễn sparse: word-context representation (10,000 chiều, chỉ 30 giá trị ≠ 0)
2. Biểu diễn dense: Embedding (300 chiều, hầu hết ≠ 0)

3. Lợi thế của dense: nén thông tin tốt, giải quyết hiện tượng đồng nghĩa/trái nghĩa bằng cách gom các chiều đặc trưng tiềm ẩn thay vì chỉ số khổng lồ từ vựng rời rạc. Tránh được "lời nguyền số chiều" giảm năng bộ nhớ.

4. Dense có tốt hơn k: không. Biểu diễn sparse vẫn chiếm ưu thế khi cần tính diễn giải cao hoặc

Scanned with CamScanner

khi làm các bài toán tìm kiếm từ khoá chính xác

9. Prediction

- Pd1: doctor và physician gần nhất, tiếp đến là doctor và hospital
- pd2: Có thay đổi. Context window hẹp (k=1,2) bắt cấu trúc cú pháp. Context window rộng (k=5,10) bắt đặc trưng chủ đề, ngữ nghĩa tổng quát
- pd3: Dim 50 -> 100 -> 300: không chắc chắn. Tăng số chiều ban đầu giúp mô hình giữ được nhiều thông tin hơn
- pd4: (Corpus 100 câu) không chắc chắn. Nền tảng của Vector nhúng là Distributional Hypothesis. 100 câu là quá nhỏ để định hình được xs thống kê đáng tin cậy

KOKUYO

Scanned with CamScanner